

Sistema de Generación Aumentada por Recuperación para Consultas de Turismo Latinoamericano con Búsqueda Híbrida, Expansión de Consultas y Fallback Web Automático

Ronald Alfonso , Abraham Rey Sanchéz

Universidad de la Habana

Resumen Se presenta un sistema de Generación Aumentada por Recuperación (RAG) para consultas de turismo en América Latina en español. Combina búsqueda híbrida BM25 + KNN sobre OpenSearch con embeddings densos de la API Mistral (1024 dimensiones), expansión de consultas mediante retroalimentación de pseudo-relevancia y expansor LLM, reordenamiento con *cross-encoder*, posicionamiento multifactor con impulso por país y retroalimentación explícita del usuario, y fallback automático a Wikivoyage. Se evalúa con 30 consultas y juicios de relevancia manuales usando MAP, MRR, Precisión, Recall y NDCG en $k \in \{5, 10, 20\}$. El recuperador base logra MAP = 0,550 y MRR = 0,887; el pipeline completo obtiene MAP = 0,395 y MRR = 0,777 con cobertura robusta ante consultas fuera del índice.

Keywords: Generación Aumentada por Recuperación · Búsqueda Híbrida · Expansión de Consultas · Reordenamiento · Recuperación de Información Turística · OpenSearch

1. Introducción

La rápida proliferación de modelos de lenguaje de gran escala (LLM) ha reavivado el interés por anclar sus salidas en corpus verificados. La Generación Aumentada por Recuperación (RAG) [1] acopla un generador LLM paramétrico con un recuperador no paramétrico, produciendo respuestas factualmente fundamentadas sin perder la fluidez de la generación neuronal.

El turismo latinoamericano presenta retos particulares: consultas muy específicas (países, ciudades, temporadas, actividades), corpus heterogéneo y escasez de benchmarks en español.

Las contribuciones de este trabajo son:

1. Arquitectura extremo a extremo de un sistema RAG para turismo latinoamericano, desplegado como microservicios Docker Compose.
2. Módulo de posicionamiento multifactor: relevancia semántica, impulso por país detectado y retroalimentación explícita del usuario como factores de ranking.

3. Dos módulos opcionales completos: expansión de consultas (LLM + PRF) y evaluación cuantitativa con métricas IR.
4. Benchmark de 30 consultas en español con juicios de relevancia.

2. Trabajo Relacionado

Fundamentos de RAG. Lewis et al. [1] introdujeron el paradigma RAG con DPR. Asai et al. [2] propusieron Self-RAG con tokens de crítica para recuperación selectiva.

Recuperación híbrida. BM25 disperso combinado con búsqueda vectorial densa supera a cada método por separado [3,4]. OpenSearch soporta pipelines de puntuación híbrida nativos.

Expansión de consultas. PRF clásico [5] y enfoques modernos con LLMs [6] se combinan en este trabajo.

Reordenamiento y RI multilingüe. *Cross-encoders* MS-MARCO [8] y benchmarks como MIRACL [9] son la base de comparación.

3. Arquitectura del Sistema

3.1. Visión General

Seis contenedores Docker Compose: *crawler* Scrapy, *procesador*, API FastAPI, frontend Vue 3/Quasar, servidor LLM Ollama y base de datos vectorial OpenSearch.

3.2. Ingesta de Datos

El crawler recopila artículos de turismo latinoamericano. Un script offline procesa el volcado XML de Wikivoyage en español, filtrando artículos de América Latina y el Caribe por coincidencia de país en título, categorías y texto, con lista de bloqueo para otras regiones.

3.3. Procesamiento e Indexación

El texto se segmenta en *chunks* de 512 tokens con solapamiento de 50. El índice OpenSearch configura el analizador **spanish** (tokenización, *stopwords* del español y *stemming* Snowball) sobre el campo BM25. En paralelo, cada *chunk* se representa con **mistral-embed** (1 024 dimensiones, L2) para búsqueda KNN con HNSW ($m = 16$, $ef_construction = 128$, similitud coseno).

3.4. Pipeline de Recuperación

Control de dominio. Clasificador LLM que bloquea el fallback web para consultas fuera del dominio turístico.

Detección de país. Detector basado en reglas para 70 alias de países. El país detectado se usa como factor de impulso en el ranking, no como filtro duro.

Expansión de consultas. Expansor LLM (parafraseo) + PRF (reponderación de términos con top- k resultados). Configurables y combinables.

Búsqueda híbrida. $s_{\text{hybrid}} = \alpha \hat{s}_{\text{BM25}} + (1-\alpha) \hat{s}_{\text{KNN}}$.

Módulo de posicionamiento multifactor.

$$R(q, d) = s_{\text{hybrid}}(q, d) \times b_{\text{país}}(q, d) \times b_{\text{feedback}}(d) \quad (1)$$

$b_{\text{país}} = 1,5$ si el país de la consulta coincide con el del documento (1 si no), $b_{\text{feedback}} = 1,2$ si el documento tiene retroalimentación positiva registrada (1 si no calificado). Con reordenamiento, s_{hybrid} se sustituye por la puntuación del *cross-encoder* (ms-marco-MiniLM-L-6-v2).

Fallback web. Cascada: índice principal $\rightarrow$ caché web $\rightarrow$ Wikivoyage en vivo. Se activa cuando el índice principal devuelve menos de un umbral mínimo de resultados.

3.5. Retroalimentación Explícita del Usuario

La interfaz incluye botones *útil* / *no útil* bajo cada respuesta. Al hacer clic se invoca POST `/feedback`, que crea el índice `feedback` en OpenSearch si no existe y persiste la tupla (*consulta*, *chunk_id*, *relevante*). El factor b_{feedback} de la Ec. 1 se aplica en tiempo real a búsquedas futuras. El proxy del servidor de desarrollo Quasar redirige `/feedback` al backend en el puerto 8000, de forma análoga a las rutas `/ask` y `/health`.

3.6. Generación de Respuestas

El top- k de *chunks* con citas se pasa a Ollama (qwen2.5:3b). La API expone `/ask` síncrono y `/ask/stream` SSE.

4. Configuración Experimental

4.1. Colección de Prueba

30 consultas en español sobre turismo latinoamericano (playas, gastronomía, senderismo, sitios culturales, seguridad, transporte) en 15 países. Juicios de relevancia binarios por pooling top-20.

4.2. Configuraciones

Baseline (híbrido puro), **Expansion** (+LLM+PRF), **Reranking** (+*cross-encoder*), **Expansion+Reranking** y **Full Pipeline**.

Cuadro 1. MAP y MRR (30 consultas). Negrita: mejor valor.

Configuración	MAP	MRR
Baseline	0,550	0,887
Expansion	0,393	0,737
Reranking	0,384	0,667
Expansion+Reranking	0,350	0,739
Full Pipeline	0,395	0,777

Cuadro 2. P@k y R@k. Negrita: mejor por columna.

Configuración	P@k			R@k		
	@5	@10	@20	@5	@10	@20
Baseline	0,620	0,487	0,307	0,380	0,601	0,750
Expansion	0,533	0,400	0,253	0,317	0,479	0,597
Reranking	0,400	0,373	0,300	0,208	0,401	0,747
Expansion+Reranking	0,440	0,387	0,253	0,243	0,431	0,584
Full Pipeline	0,547	0,403	0,253	0,326	0,473	0,582

4.3. Métricas

MAP, MRR, P@k, R@k, NDCG@k para $k \in \{5, 10, 20\}$.

5. Resultados y Discusión

El baseline domina en MAP y MRR. La expansión LLM introduce ruido en un dominio especializado; el *cross-encoder* inglés degrada el reordenamiento sobre contenido español. El Full Pipeline es arquitectónicamente superior para producción: gestiona consultas sin cobertura, aplica posicionamiento multifactor y recoge retroalimentación del usuario.

6. Manual de Usuario

6.1. Acceso

Con el sistema activo (`docker compose up -d`), acceder a `http://localhost:9000` desde cualquier navegador. No requiere registro.

6.2. Descripción de la Interfaz

La interfaz consta de tres zonas:

1. **Área de conversación:** historial de preguntas y respuestas en formato chat. Cada respuesta del asistente muestra el texto generado en tiempo real (efecto de escritura token a token) y, al finalizar, un chip con el país detectado si corresponde.

Cuadro 3. NDCG@ k . Negrita: mejor valor.

Configuración	@5	@10	@20
Baseline	0,688	0,664	0,704
Expansion	0,563	0,519	0,540
Reranking	0,443	0,451	0,580
Expansion+Reranking	0,491	0,490	0,519
Full Pipeline	0,584	0,511	0,540

2. **Panel de fuentes** (expandible): lista los fragmentos del corpus usados, con puntuación de relevancia, título y enlace a la página original. Los fragmentos se ordenan de mayor a menor relevancia según la función $R(q, d)$ de la Ec. 1.
3. **Barra de entrada**: campo de texto en la parte inferior con botón de envío.

6.3. Cómo Realizar una Consulta

1. Escribir la pregunta en lenguaje natural en español, por ejemplo: “¿Qué playas hay en Colombia?” o “¿Qué ver en Cusco en julio?”.
2. Presionar *Enter* o el botón de envío.
3. Esperar la respuesta. El chip de país confirma si el sistema detectó un filtro geográfico; el panel de fuentes muestra de dónde proviene la información.

6.4. Retroalimentación al Sistema

Bajo cada respuesta aparecen dos botones: **Útil** y **No útil**. Hacer clic en uno envía la valoración al endpoint `POST /feedback`. El botón seleccionado se resalta para confirmar el registro. Esta retroalimentación mejora el posicionamiento de documentos similares en consultas futuras mediante el factor b_{feedback} .

6.5. Posicionamiento de Resultados

Los resultados se ordenan considerando: (1) relevancia semántica (embeddings Mistral + BM25 con analizador español), (2) correspondencia de país (impulso $\times 1,5$ para documentos del país mencionado), y (3) retroalimentación positiva previa ($\times 1,2$). Las fuentes en el panel expandible reflejan ese mismo orden.

7. Opinión Crítica del Sistema

7.1. Bondades

- **Arquitectura modular y reproducible.** Cada componente corre en un contenedor Docker independiente; el sistema completo se levanta con un solo comando y puede reproducirse en cualquier máquina con Docker instalado.

- **Búsqueda híbrida efectiva.** La combinación de BM25 con analizador `spanish` y KNN denso cubre tanto la coincidencia léxica como la similitud semántica, compensando las limitaciones de cada enfoque por separado.
- **Cobertura dinámica.** El fallback de tres niveles garantiza una respuesta aunque el índice principal esté vacío: primero busca en caché web y finalmente consulta Wikivoyage en vivo, indexando el resultado para reutilización futura.
- **Posicionamiento multifactor.** El ranking incorpora relevancia semántica, impulso geográfico y retroalimentación explícita del usuario, superando el enfoque de relevancia pura.
- **Módulos opcionales funcionales.** Expansión de consultas (LLM + PRF) y evaluación cuantitativa están completamente implementados e integrados en el pipeline.

7.2. Insuficiencias y Cómo Solventarlas

- **Cross-encoder en inglés sobre contenido español.** El modelo `ms-marco-MiniLM-L-6-v2` fue entrenado sobre consultas inglesas, lo que degrada su puntuación de relevancia sobre texto en español. *Solución:* ajustar un *cross-encoder* sobre pares consulta-documento turísticos en español, o usar `cross-encoder/mmarco-mMiniLMv2-L12-H384`, variante multilingüe del mismo modelo.
- **Expansión LLM de dominio abierto introduce ruido.** El expansor LLM genera paráfrasis sin restricción de dominio, desplazando el centroide semántico de la consulta. *Solución:* incluir un prompt con ejemplos de consultas turísticas para acotar el espacio de expansión.
- **Retroalimentación no actualiza el índice vectorial.** El factor b_{feedback} impulsa documentos en tiempo de búsqueda pero no actualiza los embeddings del corpus. *Solución:* implementar un ciclo de reindexación periódico que pondere los embeddings de documentos con alta valoración positiva.
- **Popularidad y frescura no consideradas.** El módulo de posicionamiento no incorpora popularidad del destino ni frescura del documento. *Solución:* agregar factores b_{frescura} basados en `created_at` y $b_{\text{popularidad}}$ basado en frecuencia de aparición en resultados positivos.
- **Sin módulo multimodal.** El sistema procesa únicamente texto. *Solución:* integrar embeddings de imágenes con CLIP para recuperación por foto de destino, almacenándolos como vectores adicionales en el mismo índice HNSW.

8. Conclusiones

Se presentó un sistema RAG extremo a extremo para turismo latinoamericano con índice híbrido OpenSearch, analizador español para BM25, embeddings Mistral y pipeline modular. El módulo de posicionamiento combina relevancia, impulso geográfico y retroalimentación del usuario. Se implementaron dos módulos opcionales completos: expansión de consultas y evaluación cuantitativa.

El baseline híbrido domina en precisión ($\text{MAP} = 0,550$, $\text{P@5} = 0,620$); el Full Pipeline aporta cobertura robusta ($\text{MAP} = 0,395$, $\text{MRR} = 0,777$). La principal línea de mejora es ajustar el *cross-encoder* al dominio turístico en español.

Referencias

1. Lewis, P., et al.: Generación aumentada por recuperación para tareas de PLN. En: NeurIPS, vol. 33, pp. 9459–9474 (2020)
2. Asai, A., et al.: Self-RAG: Aprendiendo a recuperar y criticar. arXiv:2310.11511 (2023)
3. Ma, X., et al.: Estudio de replicación del DPR. arXiv:2104.05740 (2021)
4. Luan, Y., et al.: Representaciones dispersas, densas y de atención. TACL **9**, 329–345 (2021)
5. Rocchio, J.J.: Retroalimentación de relevancia. En: SMART Retrieval System, pp. 313–323. Prentice-Hall (1971)
6. Gao, L., et al.: Recuperación densa de cero disparos. arXiv:2212.10496 (2022)
7. Naseri, S., et al.: CEQE: Embeddings para expansión de consultas. En: ECIR 2021, pp. 467–482 (2021)
8. Reimers, N., Gurevych, I.: Sentence-BERT. En: EMNLP 2019, pp. 3982–3992 (2019)
9. Zhang, X., et al.: MIRACL: Dataset multilingüe. TACL **11**, 1114–1131 (2023)
10. Robertson, S., Zaragoza, H.: BM25 y más allá. FTIR **3**(4), 333–389 (2009)