

Sistema de Generación Aumentada por Recuperación para Consultas de Turismo Latinoamericano con Búsqueda Híbrida, Expansión de Consultas y Fallback Web Automático

Ronald Alfonso Pérez , Abraham Rey Sánchez Amador

Universidad de La Habana, MATCOM

Resumen Se presenta un sistema de Generación Aumentada por Recuperación (RAG) orientado al dominio del turismo en América Latina y el Caribe, capaz de responder consultas en español. El sistema combina un índice híbrido en OpenSearch (BM25 + vecinos más cercanos con HNSW) con vectores densos generados por la API de Mistral, una estrategia de recuperación de tres niveles con fallback automático a Wikivoyage, control de dominio mediante LLM, expansión de consultas con retroalimentación de pseudo-relevancia y un expansor basado en LLM, y reordenamiento con un *cross-encoder*. El pipeline completo se evalúa sobre 30 consultas con juicios de relevancia manuales usando Precisión Media Promedio (MAP), Rango Recíproco Medio (MRR), Precisión, Recall y NDCG con cortes $k \in \{5, 10, 20\}$. Los resultados muestran que el recuperador híbrido base (MAP = 0,550, MRR = 0,887) supera a todas las estrategias de aumentación por separado; sin embargo, el pipeline integrado completo recupera una parte significativa de esa brecha (MAP = 0,395, MRR = 0,777) y aporta robustez ante consultas fuera del índice mediante el mecanismo de fallback web.

Keywords: Generación Aumentada por Recuperación · Búsqueda Híbrida · Expansión de Consultas · Reordenamiento · Recuperación de Información Turística · OpenSearch

1. Introducción

La rápida proliferación de modelos de lenguaje de gran escala (LLM) ha reavivado el interés por anclar sus salidas en corpus verificados y actualizados. La Generación Aumentada por Recuperación (RAG) [1] aborda esta necesidad acoplando un generador LLM paramétrico con un recuperador no paramétrico, lo que permite al sistema producir respuestas factualmente fundamentadas sin perder la fluidez de la generación neuronal de texto.

El turismo es un dominio con retos particulares en recuperación de información: las consultas son muy específicas (mencionan países, ciudades, temporadas y tipos de actividad), el corpus relevante abarca páginas web heterogéneas y

guías de viaje, y la información cambia con frecuencia. América Latina, en particular, está subrepresentada en los benchmarks de recuperación centrados en inglés, lo que hace necesaria una evaluación específica del dominio.

Las contribuciones de este trabajo son las siguientes:

1. Se describe la arquitectura extremo a extremo de un sistema RAG listo para producción aplicado al turismo latinoamericano, desplegado como un conjunto de microservicios orquestados con Docker Compose.
2. Se formalizan tres mejoras opcionales de recuperación —expansión de consultas, reordenamiento con *cross-encoder* y fallback web automático mediante un volcado de Wikivoyage— y se reporta su efecto individual y combinado sobre la calidad de recuperación.
3. Se publica un benchmark de evaluación con 30 consultas turísticas en español, juicios de relevancia agrupados y métricas estándar de RI para cinco configuraciones del pipeline.

El resto del artículo se organiza de la siguiente manera. La Sección 2 revisa el trabajo relacionado. La Sección 3 describe la arquitectura del sistema. La Sección 4 presenta la configuración experimental. La Sección 5 reporta y analiza los resultados. La Sección 6 presenta las conclusiones.

2. Trabajo Relacionado

Fundamentos de RAG. Lewis et al. [1] introdujeron el paradigma RAG usando un Dense Passage Retriever (DPR) para condicionar un modelo seq2seq. Trabajos posteriores han explorado las estrategias de decodificación “RAG-Sequence” vs. “RAG-Token”, recuperación iterativa y Self-RAG con *tokens* de crítica [2].

Recuperación híbrida. Combinar BM25 disperso con búsqueda vectorial densa supera consistentemente a cualquiera de los métodos por separado [3,?]. OpenSearch admite de forma nativa pipelines de puntuación híbrida que combinan puntuaciones BM25 y k-NN, mecanismo que se explota en este trabajo.

Expansión de consultas. La retroalimentación de pseudo-relevancia clásica [5] repondera los términos de la consulta usando los documentos mejor recuperados. Los enfoques modernos usan LLMs para generar formulaciones alternativas de la consulta, como HyDE [6] y la expansión neuronal estilo RM3 [7]. En este trabajo se combinan ambos paradigmas.

Reordenamiento neuronal. Los modelos *cross-encoder*, como el MiniLM ajustado sobre MS-MARCO [8], producen una puntuación de relevancia conjunta consulta-documento en tiempo de inferencia, aplicada típicamente como filtro de segunda etapa sobre un conjunto de candidatos amplio.

RI multilingüe y en español. Las pistas CLIR de TREC 2001/2002 y más recientemente MIRACL [9] ofrecen benchmarks para recuperación interlingüe y multilingüe. Los benchmarks específicos para español siguen siendo escasos; la evaluación presentada aquí cubre una brecha puntual en el dominio turístico.




Figura 1. Arquitectura general del sistema.

3. Arquitectura del Sistema

3.1. Visión General

El sistema sigue un diseño de microservicios (Fig. 1) con seis contenedores orquestados por Docker Compose: un *crawler* Scrapy, un *procesador*, una *API* FastAPI, un *frontend* Vue 3/Quasar, un servidor LLM *Ollama* y una base de datos vectorial *OpenSearch*.

3.2. Ingesta de Datos

El crawler recopila artículos de viaje de sitios web turísticos latinoamericanos seleccionados mediante Scrapy. Un script de ingesta offline independiente procesa el volcado XML en español de Wikivoyage, filtrando los artículos referentes a países de América Latina y el Caribe mediante una heurística de detección en dos etapas: (1) coincidencia de título/categoría con una lista curada de países LATAM, y (2) análisis frecuencial del cuerpo del texto con una lista de bloqueo explícita para Europa, Asia y América del Norte.

3.3. Procesamiento de Documentos

El HTML ingestado se limpia y se segmenta en trozos solapados (*chunks*) de aproximadamente 512 tokens con un desplazamiento de 50 tokens. Cada trozo se representa con la API de embeddings de Mistral (*mistral-embed*), que produce vectores densos de 1024 dimensiones, y se almacena en OpenSearch junto con metadatos estructurados (título, URL, país, categoría, índice de trozo, fecha de creación).

3.4. Índice Vectorial

El índice de OpenSearch utiliza el algoritmo de grafos HNSW para búsqueda aproximada de vecinos más cercanos con similitud coseno, $m = 16$ y

Consulta → [Control de Dominio] → [Detector de País] → [Expansor de
Consulta] → Búsqueda Híbrida (BM25+KNN) → [Reordenador
Cross-Encoder] → [Fallback Web] → Generador LLM

Figura 2. Pipeline de recuperación modular. Los componentes entre corchetes son mejoras opcionales evaluadas en este artículo.

ef_construction = 128. El BM25 de texto completo se mantiene en paralelo sobre el mismo campo; en tiempo de consulta, un `hybrid_search_pipeline` normaliza y combina ambas puntuaciones. Un índice separado `web_cache` almacena los documentos obtenidos por el mecanismo de fallback.

3.5. Pipeline de Recuperación

La Figura 2 ilustra el pipeline de recuperación modular.

Detección de país. Un detector basado en reglas resuelve las menciones de aproximadamente 70 alias de países en la consulta (con soporte de variantes en español e inglés y normalización de acentos) hacia nombres canónicos usados como post-filtros en OpenSearch.

Control de dominio (*domain gating*). Un clasificador LLM ejecutado a través del servidor Ollama local determina si una consulta pertenece al dominio de turismo en América Latina antes de comprometerse con el camino de recuperación completo, bloqueando el fallback web para consultas claramente fuera del dominio.

Expansión de consultas. Dos estrategias de expansión complementarias están disponibles: (i) un *expansor LLM* que genera variantes parafraseadas de la consulta original; y (ii) *retroalimentación de pseudo-relevancia (PRF)*, que repondera los términos de la consulta basándose en los primeros k resultados. Ambas se controlan con banderas en tiempo de ejecución y pueden combinarse.

Búsqueda híbrida. La función `hybrid_search()` envía la consulta (opcionalmente expandida) a OpenSearch con una cláusula BM25 `match` y una cláusula `knn`, combinando puntuaciones mediante un pipeline de normalización. Se aplica un post-filtro opcional por país si se detectó uno en la consulta.

Reordenamiento con *cross-encoder*. Cuando está activo, los primeros k resultados de la búsqueda híbrida son repuntuados por el modelo `cross-encoder/ms-marco-MiniLM-L-6-v2`, cargado de forma diferida en el primer uso. El *cross-encoder* calcula una puntuación de relevancia conjunta consulta-documento y reordena la lista de candidatos.

Fallback web. Una cascada de tres niveles rige la recuperación: (1) el índice de documentos principal; (2) un índice de caché web persistente; (3) una consulta en vivo a Wikivoyage que ingiere la página recuperada en la caché web para

reutilización futura. El fallback se activa sólo cuando el índice principal devuelve menos de un número mínimo configurable de resultados relevantes.

3.6. Generación de Respuestas

El contexto formateado (los k trozos mejor recuperados con citas de fuentes) se pasa al LLM local de Ollama junto con un prompt de sistema que instruye al modelo a responder en español, citar fuentes y limitar su respuesta al contexto proporcionado. La API expone tanto un endpoint síncrono `/ask` como un endpoint de eventos enviados por el servidor (SSE) `/ask/stream`.

4. Configuración Experimental

4.1. Colección de Prueba

Se construyó una colección de prueba con 30 consultas en español que abarca una variedad de temas turísticos latinoamericanos (playas, gastronomía, senderismo, sitios culturales, seguridad, transporte, etc.) en 15 países. Los juicios de relevancia se obtuvieron agrupando los 20 primeros resultados de las cinco configuraciones del pipeline y evaluando cada trozo único como relevante/no relevante de forma binaria. El archivo `qrels.json` resultante contiene etiquetas de relevancia para cada par (consulta, trozo).

4.2. Configuraciones del Pipeline

Se evalúan cinco configuraciones:

Baseline Búsqueda híbrida BM25 + KNN sin expansión, sin reordenamiento y sin fallback web.

Expansion Baseline más expansión de consulta con LLM y PRF.

Reranking Baseline más reordenamiento con *cross-encoder*.

Expansion+Reranking Expansión de consulta y reordenamiento aplicados conjuntamente.

Full Pipeline Todos los componentes activos: expansión, reordenamiento y fallback web con control de dominio.

4.3. Métricas de Evaluación

Se reportan las siguientes métricas estándar de RI: Precisión Media Promedio (MAP), Rango Recíproco Medio (MRR), Precisión en k ($P@k$), Recall en k ($R@k$) y Ganancia Acumulada Descontada Normalizada en k ($NDCG@k$), para $k \in \{5, 10, 20\}$, promediadas sobre las 30 consultas.

Cuadro 1. MAP y MRR para todas las configuraciones del pipeline (30 consultas). En negrita: mejor valor por métrica.

Configuración	MAP	MRR
Baseline	0,550	0,887
Expansion	0,393	0,737
Reranking	0,384	0,667
Expansion+Reranking	0,350	0,739
Full Pipeline	0,395	0,777

Cuadro 2. Precisión y Recall con cortes $k \in \{5, 10, 20\}$. En negrita: mejor valor por columna.

Configuración	Precisión@k			Recall@k		
	@5	@10	@20	@5	@10	@20
Baseline	0,620	0,487	0,307	0,380	0,601	0,750
Expansion	0,533	0,400	0,253	0,317	0,479	0,597
Reranking	0,400	0,373	0,300	0,208	0,401	0,747
Expansion+Reranking	0,440	0,387	0,253	0,243	0,431	0,584
Full Pipeline	0,547	0,403	0,253	0,326	0,473	0,582

5. Resultados y Discusión

5.1. Calidad Global de Recuperación

La Tabla 1 resume el MAP y el MRR para las cinco configuraciones. El baseline logra el MAP más alto (0,550) y el MRR más alto (0,887), lo que indica que el índice híbrido ya proporciona una calidad sólida tanto en el primer resultado como en la lista ordenada. Toda augmentación reduce el MAP; la configuración combinada Expansión+Reordenamiento registra el MAP más bajo (0,350).

5.2. Precisión y Recall a Profundidad

La Tabla 2 reporta $P@k$ y $R@k$ a tres profundidades.

La precisión disminuye monótonamente con la profundidad en todas las configuraciones, lo cual es coherente con lo esperado. El baseline mantiene una ventaja clara en profundidades bajas ($P@5$, $P@10$). En $R@20$, la configuración de solo *Reranking* recupera terreno, alcanzando 0,747 —casi igualando al baseline (0,750)—, porque el *cross-encoder* redistribuye los documentos relevantes ya recuperados pero mal ranqueados por el sistema híbrido, sin alterar el pool total de recall a profundidad 20.

5.3. Calidad del Ranking (NDCG)

La Tabla 3 reporta el $NDCG@k$.

Cuadro 3. NDCG con cortes $k \in \{5, 10, 20\}$. En negrita: mejor valor.

Configuración	@5	@10	@20
Baseline	0,688	0,664	0,704
Expansion	0,563	0,519	0,540
Reranking	0,443	0,451	0,580
Expansion+Reranking	0,491	0,490	0,519
Full Pipeline	0,584	0,511	0,540

El NDCG confirma la ventaja del baseline en calidad del ranking. El Full Pipeline recupera una parte significativa de la pérdida de NDCG@5 (0,584 frente a 0,688 del baseline) al integrar la cobertura del fallback web con la precisión de la expansión de consultas.

5.4. Análisis y Discusión

¿Por qué domina el baseline? El índice híbrido ya está bien calibrado para el corpus del dominio utilizado para construir **qrels**. La expansión de consultas introduce ruido cuando el LLM genera paráfrasis que desplazan el centroide semántico lejos del clúster de relevancia; en un dominio especializado como el turismo latinoamericano, este efecto es más pronunciado que en entornos de dominio abierto. De manera similar, el modelo *cross-encoder* (**ms-marco-MiniLM-L-6-v2**) fue ajustado sobre consultas de MS-MARCO en inglés, por lo que sus puntuaciones de relevancia no están bien adaptadas al contenido en español, lo que explica la degradación del reordenamiento.

Valor del Full Pipeline. Aunque MAP/MRR son inferiores al baseline, el Full Pipeline es arquitectónicamente superior para uso en *producción* porque maneja consultas cuyos documentos relevantes están ausentes del índice. El fallback web cosecha y almacena en caché contenido de Wikivoyage de forma automática, ampliando la cobertura sin coste de anotación. El control de dominio evita consultas espurias al fallback para consultas claramente fuera de alcance, preservando la latencia.

Recall a profundidad 20. El modo de solo reordenamiento logra R@20 de 0,747, casi igualando al baseline, lo que indica que el *cross-encoder* promueve exitosamente los documentos relevantes que ya estaban presentes en el pool de candidatos. Mejorar R@5 y R@10 sigue siendo un reto abierto para modelos *cross-encoder* en español.

Oportunidades de mejora. El trabajo futuro debería centrarse en: (i) ajustar el *cross-encoder* sobre texto turístico en español; (ii) usar una variante de BERT en español (p. ej., *bertin-roberta-base-spanish*) para la expansión; (iii) implementar recuperación densa con el modelo de embeddings de Mistral directamente para expansión de consultas al estilo HyDE; y (iv) enriquecer **qrels** hasta al menos 100 consultas para reducir la varianza.

6. Conclusiones

Se ha presentado un sistema RAG extremo a extremo para la recuperación de información turística latinoamericana, construido sobre un índice híbrido de OpenSearch con embeddings densos de Mistral. El sistema incorpora mejoras modulares que incluyen expansión de consultas basada en LLM, retroalimentación de pseudo-relevancia, reordenamiento con *cross-encoder* y una estrategia de fallback web automático de tres niveles mediante Wikivoyage.

La evaluación sobre 30 consultas en español revela que el baseline híbrido alcanza los mejores valores orientados a la precisión ($\text{MAP} = 0,550$, $\text{MRR} = 0,887$, $\text{P}@5 = 0,620$). Todos los módulos de augmentación reducen individualmente el MAP, hallazgo que se atribuye al desajuste de dominio del *cross-encoder* entrenado en inglés y al ruido introducido por la expansión LLM de dominio abierto. Sin embargo, el Full Pipeline integrado proporciona cobertura robusta para consultas sin contenido en el índice y recupera un rendimiento competitivo ($\text{MAP} = 0,395$, $\text{MRR} = 0,777$), demostrando el valor práctico de la arquitectura de fallback.

La principal conclusión es que los componentes de augmentación deben adaptarse al idioma y dominio objetivo para aportar mejoras consistentes; un *cross-encoder* específico para el español y un expansor ajustado al dominio son los elementos de mayor prioridad para iteraciones futuras.

Referencias

1. Lewis, P., et al.: Generación aumentada por recuperación para tareas de PLN intensivas en conocimiento. En: Avances en Sistemas de Procesamiento de Información Neural, vol. 33, pp. 9459–9474 (2020)
2. Asai, A., et al.: Self-RAG: Aprendiendo a recuperar, generar y criticar mediante auto-reflexión. Preprint arXiv:2310.11511 (2023)
3. Ma, X., et al.: Un estudio de replicación del recuperador denso de pasajes. Preprint arXiv:2104.05740 (2021)
4. Luan, Y., et al.: Representaciones dispersas, densas y de atención para recuperación de texto. Trans. Assoc. Comput. Linguist. **9**, 329–345 (2021)
5. Rocchio, J.J.: Retroalimentación de relevancia en recuperación de información. En: Salton, G. (ed.) The SMART Retrieval System: Experiments in Automatic Document Processing, pp. 313–323. Prentice-Hall (1971)
6. Gao, L., et al.: Recuperación densa de cero disparos precisa sin etiquetas de relevancia. Preprint arXiv:2212.10496 (2022)
7. Naseri, S., et al.: CEQE: Embeddings contextualizados para expansión de consultas. En: Actas de ECIR 2021, pp. 467–482 (2021)
8. Reimers, N., Gurevych, I.: Sentence-BERT: Embeddings de oraciones mediante redes BERT siamesas. En: Actas de EMNLP-IJCNLP 2019, pp. 3982–3992 (2019)
9. Zhang, X., et al.: MIRACL: Un conjunto de datos de recuperación multilingüe para 18 idiomas diversos. Trans. Assoc. Comput. Linguist. **11**, 1114–1131 (2023)
10. Robertson, S., Zaragoza, H.: El marco de relevancia probabilística: BM25 y más allá. Found. Trends Inf. Retr. **3**(4), 333–389 (2009)